

VENKATA YASHWANT KUMAR BHYRI

(+86) 15914122353 | 123040005@link.cuhk.edu.cn | [LinkedIN](#) | 香港中文大学 (深圳) | Shenzhen, China

教育背景: 香港中文大学 (深圳) | 计算机科学与工程 工学学士 | 2023 年 - 2027 年 (预计)

- 数据科学学院全额入学卓越奖学金** : 授予学术表现顶尖的新生。
- 广东省政府优秀国际学生奖学金** : 表彰杰出的国际学生学者。
- 数据科学学院首席学业助理导师 (2025)** : 领导并指导同侪学业项目, 展现卓越的技术沟通与领导力。

核心技术技能:

- | |
|---|
| <ul style="list-style-type: none">工程开发核心栈: Python (FastAPI, Pydantic, PyTorch, Transformers, 服务编排, Agent Runtime, 检索增强与评测系统)、TypeScript / JavaScript, C++, SQL, Linux, Docker, Redis, ONNX Runtime, TensorRT, FFmpeg |
| <ul style="list-style-type: none">多模态大模型与智能体系统: VLM / 多模态大模型应用 (视觉 / 音频 / 文本), OpenAI-Compatible Inference end-points, 多智能体编排 (Agentic AI), Agent Harness, Tool Routing, Agent Handoff, State Checkpoint, LangGraph, Prompt Engineering, Context Engineering, Prompt / Context Compiler, TTS / ASR, OCR, VQA |
| <ul style="list-style-type: none">检索、记忆与知识增强: GraphRAG, FAISS, Qdrant, 向量数据库应用, 混合检索 (BM25 + 向量检索 + 重排序), 长时记忆 / 持久化记忆, 语义检索, RAG workflow 设计, DSPy 程式提示优化, Schema-aware Prompting, 多模态 Grounding |
| <ul style="list-style-type: none">评测、优化与部署: OpenTelemetry 可观测性, RL-style evaluation and self-improvement loops, LLM-as-Judge 评估体系, Execution Accuracy (EX) 评测协议, Benchmark 构建, Regression Testing, Prompt / Agent Evals, Chain-of-Thought 错误分析, 幻觉诊断, 错误归因, 成本归因, BERTScore / ROUGE, INT8 量化 (PTQ / QAT), 结构化剪枝, 模型蒸馏, TensorRT, ONNX Runtime, TFLite-Micro, 边缘端部署, DSP / NPU C++ 算子级优化, 低时延推理, 延迟与内存优化, SDK 集成与封装 |

工作与科研经历:

1. AI Agent 开发工程师 (实习) | AIGC 算法方向 | Wondershare Filmora 万兴科技集团股份有限公司 | 深圳 2026.01 - 2026.07

- 面向 Filmora 场景搭建多智能体 AIGC workflow 编排层, 将单次用户创作请求拆解为可执行的分阶段多模态生产链路, 支撑企业级创作软件中的视频生成/编辑、音频生成、对白/TTS、字幕、视觉增强等能力的自动化协同
- 参与构建多模态 LLM 应用链路, 围绕文本理解、视觉语义控制、音频处理与内容编排等能力设计 Agent 协同流程, 使系统能够结合用户意图、上下文约束与编辑目标, 对多模态内容进行统一生成、编辑与组装。
- 设计并实现 Agent Harness / Runtime 关键机制, 包括 tool routing、agent handoff、state checkpoint、schema-bound prompt contracts、prompt versioning 以及 human-in-the-loop 审批/再生成流程, 提升多代理 workflow 在企业软件集成场景下的稳定性、可控性与可调试性。
- 原型实现趋势研究智能体, 结合记忆检索与 ML 推荐模块, 将 **700+** 实时短视频创意趋势信号 (爆款音频、主题风格、脚本 hook、色彩方案、节奏模式、字幕与效果偏好等) 转化为可复用 context packets、skill files、设计文档与编辑控制参数。

- 设计语义化 Prompt / Context Compiler，融合用户输入、趋势推荐、检索上下文及多 Agent 中间结果，将高层创作意图编译为可执行的模型/工具调用指令，用于自动化、趋势对齐的多模态内容生成与编辑。
- 建立 alpha/beta 工作流可观测性与 RL-style 评测反馈闭环，接入类 OpenTelemetry 的 traces、tool-call spans、agent handoff 链路、guardrail events、回归测试、延迟/错误指标与 API 成本归因；最终将 API 成本优化 **28%**，并将编排层时延控制在端到端生成时延的约 **2%**。

2. AI 模型工程师 / 音频算法开发 | 奥泰克微电子（深圳） | 2025.07 – 2025.09

- 主导设计并落地端到端 TinyML 音频分类流水线，集成 DSP 模块实现实时 log-Mel 频谱图 / MFCC 特征提取，并基于 YAMNet 架构构建定制化轻量音频模型，用于资源受限场景下的实时推理。
- 完成模型在 **700 MHz DSP + 16 MB 定制 NPU** 环境中的部署与适配，通过 INT8 量化、结构化剪枝、手写 C++ 算子优化等方式，将模型压缩并封装为可集成 Docker 化 SDK，最终实现 **<10 ms 延迟、93%+ 准确率、14 倍压缩比**
- 针对训练过程中的数值不稳定问题优化 Softmax 及相关训练环节，提升低资源音频分类场景下的收敛稳定性与训练鲁棒性，为后续嵌入式落地提供稳定模型基础。

3. 多模态大语言模型研究助理 | 香港大学 × Google Cloud 合作项目 | 2025.06 – 2025.09

- 重构并扩展包含 **12,751+** 样本的复杂多模态基准测试框架，基于 BIRD-SQL 数据集开展 VQA + Text-to-SQL 联合评测，用于系统分析视觉语言模型在图文表混合场景下的推理表现。
- 引入 OCR 驱动的情境 grounding 与 schema-aware prompting 机制，增强 LLaMA、GPT-4 等模型在视觉信息约束下的数据库查询生成与跨模态推理能力。
- 架构基于 LangGraph + FAISS 的检索推理工作流，并结合 DSPy 进行模式感知提示优化，使模型能够围绕用户意图、表结构信息与视觉上下文执行更稳健的推理链路。
- 设计并落地 **Execution Accuracy (EX)** 评测协议，对 **95+** 大规模数据库上的 CoT 推理失败案例、幻觉现象与 SQL 生成偏差进行系统化诊断，为多模态推理系统的评估与改进提供可复用框架。

4. AIGC 视频生成算法优化 研究助理 | 香港中文大学（深圳） | 2024.05 – 2024.09

- 构建智能体驱动的“脚本到视频”自动化生成流程，结合 RAG 与 Qdrant 向量数据库实现视觉语义上下文检索，使大语言模型能够基于外部上下文组织 Stable Diffusion 渲染与 FFmpeg 后处理链路，整体流程效率提升 **56%**。
- 为 ALLaVA 视觉语言模型设计混合检索管线，融合 **BM25 精确匹配 + 自适应语义重排序**，对 **130 万条** 视频指令样本进行有效筛选与降噪，提升下游训练与检索质量。
- 面向多模态视频生成场景优化检索准确率与生成可控性，最终将多模态检索准确率提升 **46%**，增强模型对脚本语义与视觉表达之间的对齐能力。

5. 小语言模型精研 研究助理 | 香港中文大学自然语言处理小组 (NLP) | 2023.10 – 2024.01

- 基于 Hugging Face TRL 自动化小语言模型蒸馏流程，并引入 “LLM-as-Judge” 机制过滤含幻觉的合成训练数据，使模型输出事实错误率降低 **31%**
- 搭建覆盖 **200+** 组模型输出的评测流程，并开发 Streamlit 可视化仪表板，用于展示 BERTScore 等指标与模型对齐表现

VENKATA YASHWANT KUMAR BHYRI

(+86) 15914122353 | 123040005@link.cuhk.edu.cn | [LinkedIN](#) | 香港中文大学 (深圳) | Shenzhen, China

核心项目经历: [Link to personal portfolio website](#)

MindScape | 多模态精神科临床智能辅助系统

技术栈 : SenseVoice / Emotion2Vec+ / MedCPT / GMU Fusion / HNSW / FAISS / BM25 / RRF / BioLinkBERT / DeBERTa-v3 / DSM-5 Rule Engine / Docker / Kubernetes / OAuth2 / JWT

- 设计并实现面向精神科临床辅助场景的多模态智能系统，将患者情感语音信号、文本转录、CV/副语言学线索转化为具备证据约束的临床辅助推理输入，用于支持医生进行更系统的状态判断与决策参考。
- 构建 **7 层 Behavioral State Vector** 建模管线，将语音分解为 linguistic transcripts、SenseVoice event tokens、Emotion2Vec+ affect embeddings 及 longitudinal patient-state signals，并通过 **Gated Multimodal Unit (GMU)** 融合为可复用的临床状态表示。
- 搭建混合式临床 RAG 推理链路，结合 **MedCPT dense embeddings**、**HNSW/FAISS 向量检索**、**BM25 词法召回**、**RRF 融合**、**BioLinkBERT 交叉重排**，提升临床知识召回的相关性与覆盖度。
- 在下游推理层中引入 **DSM-5 grounded CoT-LLM reasoning**、**DeBERTa-v3 NLI 验证与确定性 DSM-5 规则门控**，增强精神科辅助推理的证据一致性、安全性与可解释性。

Antigravity | AI-Native 技术面试平台

技术栈 : Next.js / React / TypeScript / FastAPI / Redis / WebRTC / WebSocket / ASR/STT / TTS / LLM APIs / RBAC / Docker / Playwright

- 设计并落地端到端 AI-native 技术面试平台，通过实时语音交互完成自动化技术面试流程，系统基于异步多智能体架构支持多轮追问、动态难度调整与结构化能力评估。
- 围绕技术招聘场景构建四类核心评估模块：**简历声称能力核验**、**系统设计深挖**、**沙箱编码表现评估**、**工程判断与 trade-off 分析**，使系统能够从“会说什么”进一步评估“真正能做什么”。
- 结合语音链路、LLM 推理与后端评测逻辑，生成 evidence-backed hiring intelligence reports，为 HR 与技术团队提供可追溯、可解释的候选人能力分析结果。
- 平台已服务 **250+** 候选人与招聘团队，作为 ATS 之后的技术初筛层，帮助降低人工筛选成本，并提升基于真实工程能力与推理能力的候选人排序质量。